해양·항만 AX 실증센터 기업 수요 심층면담 질의서

개정본 Rev 2.1 · 2026. 10. 21.(수) 심층면담용

항목	내용
조사목적	기업의 현장 애로사항, AI 활용 수요, 데이터·인프라 요구사항 및 실증 참여의향을 파악하여 ISP·ISMP 구축·운영계획에 반영
면담일시	2026. 10. 21.(수) / 면담 약 90분
진행방식	①사전서베이: 면담 7일 전까지 서면(XLSX) 작성·회송 ②심층면담: 정량값 근거 확인 및 미확인 항목 보완
문항구성	총 57문항 = 기본정보 3(M01~M03) + 본 문항 51(Q01~Q50, Q29-2) + 응답 동의 3(C01~C03) 사전 27문항 / 면담 30문항 / ★핵심 12문항
개정내용	원 질의서 32문항 취지 전량 승계·보강, 신설 20문항, IX장(실증 참여의향) 신설 ※ 상세: 부록 B
보안등급	대외비 —응답은 익명화·집계 후 보고서에 반영

작성 안내

①**GPU-시간(GPU-h) = GPU 카드 수 × 실행 시간(시)** 예) H100 4장으로 6시간 학습 = 24 GPU-h

②모르는 수치는 **'미확인'**으로, 추정값은 **근거·가정**과 함께 적어 주십시오. (추정·미확인 수치는 집계 시 할인 반영되며, ISP 수요총량의 신뢰도 등급 표기에 사용됩니다)

③[LLM]·[LLM·에이전트]·[영상]·[배치] 표시 항목은 해당 유형만 답하고, 나머지는 **'해당없음'**으로 적어 주십시오.

④정량 문항은 지정된 단위(TB, 장, 시간 등)로 기재해 주십시오. 단위 없이 서술하면 재확인 연락을 드립니다.

⑤응답은 '수요산정 시트(XLSX)'에 입력되어 기업별 GPU-h·필요 카드 수가 자동 산출되고, 보수·표준·과대 3개 시나리오로 집계됩니다.

문항 표시 사전 면담 전 서면 작성 면담 면담 중 확인 ★ 핵심 수요 산정 직결 문항

문항 구성

장	주제	문항	사전	면담	★
-	기본정보	M01~M03	3	0	-
I	기업 및 PoC 기본현황	Q01~Q06	1	5	2
II	AI 모델 및 기술구조	Q07~Q13	5	2	2
III	데이터 규모 및 처리 특성	Q14~Q20	5	2	1
IV	GPU 학습 자원 수요	Q21~Q26	4	2	1
V	GPU 추론 자원 수요	Q27~Q32	5	2	3
VI	GPU 이용 형태 및 확장성	Q33~Q36	1	3	-
VII	실증환경 및 기술지원	Q37~Q43	2	5	1
VIII	실증성과 및 투자 타당성	Q44~Q46	1	2	1

장	주제	문항	사전	면담	★
IX	실증 참여의향	Q47~Q50	0	4	1
-	응답 동의	C01~C03	0	3	-
부록 A	GPU 수요 산정식과 예시	-			
부록 B	원 질의서 대비 조정 내역·문항 대응표	-			
부록 C	제출·회수 안내	-			

기본정보 기업·응답자 및 면담 기록 · M01~M03

번호	문항 및 응답란
M01 사전	**기업 기본정보** ▪ 기업명(법인등기명): _____ ▪ 사업자등록번호: _____ ▪ 업종 □ 터미널 운영 □ 해운·물류 □ 항만안전·감시 □ 자율운항·해상장비 □ 수산물·어업 □ 해양환경·재난 □ 조선·플랜트 □ AI/SW 공급사 □ 기타(_____) ▪ 설립연도: _____년 ▪ 임직원: _____명 ▪ 매출 구간: □ 5억 이하 □ 5~50억 □ 50~300억 □ 300억 이상 ▪ AI 전담인력: _____명 (센터 이용 가능 인력 _____인월/년)
M02 사전	**응답자 정보** ▪ 성명: _____ ▪ 직급·역할: _____ ▪ 연락처(휴대): _____ ▪ 이메일: _____ ▪ 본 PoC에서의 역할: □ 의사결정자 □ 총괄기획 □ 기술수행 □ 기타(_____)
M03 사전	**면담 기록** ※ 수행기관 작성 ▪ 사전서베이: □ 제출(제출일 ____.__.__) □ 미제출(면담 시 전량 작성) ▪ 면담일자: ____.__.__ ▪ 방식: □ 현장방문 □ 온라인(화상) □ 서면 대체 ▪ 면담 수행자: _____ ▪ 기업 동석자: _____

Ⅰ. 기업 및 PoC 기본현황 무엇을, 왜 실증하는가 · Q01~Q06

번호	문항 및 응답란
Q01 면담	**실증하려는 AI 서비스·기술은 무엇입니까?** ▪ 서비스·기술 개요: _____ ▪ 대상 업무·장비: _____ ▪ 현재 사용 중인 방식(대체 대상): _____
Q02 사전	**현재 기술개발 단계는 어디에 해당합니까?** □ 아이디어 □ 시제품 □ 자체 검증 □ 현장 실증 진입 ▪ (자체 검증·현장 실증인 경우) 검증 장소: _____ 수행 기간: ____개월
Q03 면담	**해결하려는 해양·항만 현장의 문제는 무엇입니까?** ▪ 문제 내용: _____ ▪ 발생 장소·주체: _____ ▪ 발생 빈도: 월 _____회 ▪ 1회 발생 시 손실: 작업지연 ____시간 / 비용 ____만원 / 사고 ____건
Q04 면담 ★ 핵심	**실증 KPI와 목표, 판정 기준은 무엇입니까?** ▪ 지표명: _____ ▪ 현재 기준선(baseline): _____ (□ 측정자료 보유 □ 미보유) ▪ 목표값: _____ ▪ 측정 주체: □ 자사 □ 제3기관 □ 센터 공동검증

번호	문항 및 응답란
	▪ 판정 기간: 착수 후 ____주 ▪ 통과 기준 사전 문서화: □ 완료 □ 작성 예정
Q05 면담	**성능지표 외의 기대효과와 연간 환산 금액은 어느 정도입니까?** □ 매출·수주 증대 _____만원/년 □ 원가·인건비 절감 _____만원/년 □ 안전사고 감축 _____건/년 □ 규제·민원 대응 _____건/년 □ 기타: _____
Q06 면담 ★ 핵심	**AI 도입의 가장 큰 장애요인은 무엇입니까?** (보기 번호로 1·2순위 기재) ▪ 1순위: ( ) ▪ 2순위: ( ) ①예산 ②전담인력 ③데이터 확보·반출 ④규제·인증 ⑤검증 인프라(GPU·현장) ⑥경영층 설득 ⑦기타(_____)

Ⅱ. AI 모델 및 기술구조 어떤 모델을 어떻게 쓰는가 · Q07~Q13

번호	문항 및 응답란
Q07 사전	**사용(예정) AI 모델 유형은 무엇입니까?** (복수 선택) □ LLM □ VLM □ 영상이해·객체검출 □ 시계열 예측 □ 최적화(배차·야적·선석) □ 음성(STT/TTS) □ 문서요약·생성 □ 기타(_____)
Q08 사전	**모델명·버전·파라미터 수·프레임워크는 무엇입니까?** ▪ _____ ※ 예) YOLOv8s 11M / PyTorch 2.3, Qwen2.5-32B / vLLM ※ 상용 API만 사용하는 경우 'API 전용'으로 기재
Q09 사전	**모델 적용 방식은 무엇입니까?** □ 상용 API만 □ 기존 모델 추론만 □ LoRA/PEFT 미세조정 □ Full FT □ 신규 학습(스크래치)
Q10 사전 ★ 핵심	**추론은 어떤 방식으로 수행합니까?** (GPU 수요 성립 여부를 가르는 핵심 문항) □ 자체 호스팅(센터 GPU 사용) □ 상용 API만 사용 □ 하이브리드 ▪ 상용 API·외부 호스팅으로 처리할 워크로드 비중: _____% ▪ 상용 API 사용 시: 월 요청수·토큰량 _____ 월 비용 _____만원 ▪ 자체 호스팅을 하지 않는 이유 □ 고성능 카드 미보유 □ 운영인력 부재 □ 비용 □ 내부 보안정책 □ 불필요(경량 모델)
Q11 면담	**현재 사용 중인 CPU·GPU 사양과 관측된 성능 한계는 무엇입니까?** ▪ GPU: 기종 _____ × ____장 (VRAM ____GB) ▪ CPU·RAM: _____ ▪ 한계 사례: _____ ※ 예) 'H100×1에서 7B FP16 응답 6초/질문', '재학습 1회 3일 소요'
Q12 사전 ★ 핵심	**경량화·양자화를 어디까지 수용할 수 있습니까?** (센터 구축 규모 과소·과대 방지에 사용) □ FP16/BF16 이상 필수 □ FP8·INT8 허용 □ INT4 허용 □ 증류·프루닝 허용(____B → ____B) ▪ 허용 가능한 정확도 저하(검증 데이터셋 기준): _____%p 이내

번호	문항 및 응답란
Q13 면담	**비(非)NVIDIA 가속기(국산 NPU 등)로 대체 실증할 의사가 있습니까?** □ 수용 가능 —조건: _____ (예: 연산자 지원, 전환 공수) □ 어려움 —사유: _____

Ⅲ. 데이터 규모 및 처리 특성 얼마나 많은 데이터를, 어떤 제약 아래 다루는가 · Q14~Q20

번호	문항 및 응답란
Q14 사전	**실증에 필요한 데이터의 유형별 물량은 얼마입니까?** (해당 항목만 기재) □ CCTV·감시영상 _____시간 / _____TB □ 드론·항공영상 _____시간 / _____TB □ 소나·수중음향 _____시간 □ AIS·선박위치 _____만 건 / _____GB □ 기상·조류·수심 _____GB □ 센서·IoT(크레인·AGV·컨테이너) _____GB □ 문서·도면(PDF·HWP·CAD) _____건 / _____GB □ 이미지(결함·현장) _____만 장 □ 음성 _____시간 □ 기타: _____
Q15 사전	**보유 데이터의 총량은 어느 정도입니까?** ▪ 총량: _____TB (_____만 건·프레임) ▪ 해상도·샘플링: _____×_____ @____fps (또는 ____kHz) ▪ 평균 파일 크기: _____MB ▪ 라벨링 완료 비율: _____%
Q16 사전	**데이터는 얼마나 증가합니까?** ▪ 신규 학습 데이터: _____GB/월 (라벨링 필요량 _____건/월) ▪ 추론(스트리밍) 데이터: _____GB/일 또는 영상 _____fps 상시 수신 ▪ 보관 계획: _____년 (누적 예상 용량 _____TB)
Q17 사전	**라벨링·전처리 현황과 필요한 지원은 무엇입니까?** ▪ 현재 라벨링 주체: □ 내부(_____명) □ 외주(단가 _____원/건) □ 미실시 ▪ 필요 지원: □ 센터 라벨링 대행 □ 전처리 파이프라인 구축 □ 어노테이션 도구 □ 불필요
Q18 면담	**데이터 반출·보안에 제한이 있습니까?** (해당 항목 모두 선택) □ 항만보안·국가중요시설 □ 선사·터미널 운영사 반출 동의 필요 □ 개인정보(CCTV 얼굴·선원) □ 위치정보 반출 제한 □ 상용 데이터 라이선스(AIS·위성) □ 영업비밀·계약상 비밀 □ 제한 없음 ▪ 승인 주체: _____ ▪ 승인 예상 소요기간: _____주
Q19 면담 ★ 핵심	**데이터 반출이 불가하다면 어떤 조치가 필요합니까?** (센터 시설·운영 기획에 사용) □ 센터에 상주하여 직접 작업 가능(인원 ____명, 기간 ____개월) □ 격리 작업공간(VDI·망분리) 제공 시 센터 활용 □ 센터의 비식별·익명화 대행 서비스 필요 □ 전량 자사 처리 후 결과물만 협의

번호	문항 및 응답란
Q20 사전	**보유한 보안 인증과 센터에 요구하는 보안 조치는 무엇입니까?** ▪ 보유 인증: □ ISMS □ ISMS-P □ ISO 27001 □ 없음 ▪ 요구 보안 조치(접근통제·감사로그·물리보안 등): _____

IV. GPU 학습 자원 수요 학습에 GPU-시간이 얼마나 필요한가 · Q21~Q26

번호	문항 및 응답란
Q21 사전	**GPU가 필요한 학습 작업은 무엇입니까?** (복수 선택) □ 사전학습 □ Full FT □ LoRA/PEFT □ 주기 재학습 □ 평가·벤치마크 □ 합성데이터 생성 □ 시뮬레이션
Q22 면담 ★ 핵심	**1회 학습 실험의 GPU 부하는 어느 정도입니까?** ▪ GPU 기종: _____ ▪ 카드: ____장 ▪ 카드당 VRAM: ____GB ▪ 1회 실행 시간: _____시간 → 1회 실험 = _____GPU-h (카드 수 × 시간) ▪ 근거: □ 자사 실측 □ 공개 벤치마크 □ 외부 상담 추정 ▪ 실측 로그·스크립트 사본 제출: □ 가능 □ 불가
Q23 사전	**학습 실행 빈도와 동시성은 어느 정도입니까?** ▪ 학습·재학습: 월 _____회 (□ 1회 미만 □ 1~2회 □ 3~5회 □ 6~10회 □ 11회 이상) ▪ 실험 배수(하이퍼파라미터 탐색·재시도 포함): ×_____배 ▪ 동시에 병렬 실행하는 실험 수: _____개
Q24 사전	**학습 본연 외의 간접 GPU 사용 비율은 얼마입니까?** (전처리·데이터 증강·평가·데모 빌드·재실행 손실) ▪ 간접 사용 비중: _____% ※ 참고: 통상 20~40% ▪ 재실행이 잦은 사유(있는 경우): _____
Q25 사전	**GPU가 필요한 기간은 언제입니까?** ▪ 착수 희망: _____년 _____월 ▪ 종료 희망: _____년 _____월 (총 _____개월) ▪ 기한이 고정된 사유: □ 발주·계약 □ 공모 마감 □ 성수기 전 출시 □ 기타 (_____)
Q26 면담	**분산 학습·멀티 GPU 구성이 필요합니까?** □ 멀티노드 학습: ____노드 × ____장 = 총 ____장 인터커넥트: □ NVLink □ InfiniBand □ RoCE □ 무관 □ 싱글노드 내 멀티 GPU □ 불필요 ▪ 추론 시 모델 1개를 여러 카드에 분할(tensor parallel): □ 필요(모델당 ____장) □ 불필요

V. GPU 추론 자원 수요 서비스 운영에 GPU가 몇 장 필요한가 · Q27~Q32

번호	문항 및 응답란
Q27 사전	**추론 처리 방식은 무엇입니까?** □ 실시간(1초 이내) □ 준실시간(1초~5분) □ 배치(완료 여유시간 _____시간)

번호	문항 및 응답란
Q28 사전 ★ 핵심	**피크 부하는 얼마입니까?** (아래 단위 중 1개를 골라 값 기재) □ _____ req/초 □ _____ 영상 프레임/초 □ _____ tok/초 □ _____ 동시 세션 □ _____ req/일(배치) ▪ 동시 이용자 수: _____명 ▪ 월 총 요청 수: _____건
Q29 면담 ★ 핵심	**GPU 1장의 실측 처리량은 얼마입니까?** (GPU-h 환산의 결정값 —가장 중요한 문항) "보유하거나 임시 대여한 GPU 1장에 해당 모델을 올렸을 때, Q28과 같은 단위로 초당 몇 건을 처리합니까?" ▪ GPU 기종: _____ ▪ 정밀도: _____ ▪ 처리량: _____ /초 (Q28과 동일 단위) ▪ 근거: □ 실측 □ 제조사 스펙 □ 미확인 ※ '미확인'이면 다음 문항(Q29-2)에 필요 카드 수를 직접 기재해 주십시오.
Q29-2 면담 ★ 핵심	**(Q29 미확인 시) 피크 기준으로 추론에 필요한 GPU는 몇 장입니까?** ▪ 필요 GPU: ____장 ▪ 근거: _____
Q30 사전	**요청 1건의 연산 부담은 어느 정도입니까?** (해당 모델 유형만 기재) ▪ [LLM] 평균 입력 ____tok / 출력 ____tok / 최대 컨텍스트 ____tok 추론(reasoning) 모드: □ 사용 □ 미사용 ▪ [LLM·에이전트] 사용자 1요청당 모델 호출 ____회 RAG 임베딩·리랭크 별도 부하: □ 있음 □ 없음 ▪ [영상] 카메라 ____대 × ____fps × 해상도 _____ / 프레임당 알고리즘 ____개 엣지 사전선별: □ 적용(센터 전송 비율 ____%) □ 미적용 ▪ [배치] 월 총 처리량: 영상 ____시간 / 문서 ____쪽 / 기타 ____건
Q31 사전	**허용 가능한 최대 응답시간·지연은 얼마입니까?** ▪ [LLM] 첫 토큰까지 ____초 이내 / 전체 응답 ____초 이내 ▪ [영상] 프레임 처리 ____초 이내 / 경보 발령까지 총 지연 ____초 이내 ▪ [배치] 완료까지 여유시간 ____시간
Q32 사전	**추론 서비스 운영 시간은 어떻게 됩니까?** □ 24시간 × 7일 □ 주 ____일 × 일 ____시간 □ 기타(_____) ▪ 피크/평시 배수: ×_____ ▪ 요구 가용률: ____% (연간 중단 허용 ____시간)

VI. GPU 이용 형태 및 확장성 어떻게 나눠 쓰고, 앞으로 얼마나 늘어나는가 · Q33~Q36

번호	문항 및 응답란
Q33 면담	**GPU를 전용으로 써야 합니까, 공유해도 됩니까?** □ 전용 필요 —사유: □ 보안 □ 성능 □ 규격검증 □ 기타(____) □ 공유 허용 —조건: □ 작업공간 논리격리 □ 데이터 비혼재 □ 대기 허용(____시간 이내) □ 조건 없음
Q34 면담	**대기·선점(preemption) 정책을 어디까지 수용할 수 있습니까?** □ 예약제 선호(____일 전 신청) □ 선착순 대기 허용(최대 _____시간) □ 실행 중 중단 허용 —체크포인트 주기 ____분, 재실행 손실 허용 ____시간

번호	문항 및 응답란
Q35 사전	**향후 1~3년의 확장 전망은 어떻습니까?** (현재 대비 배수로 기재) ▪ 데이터 ×_____ ▪ 이용자·카메라 ×_____ ▪ 모델 규모(파라미터) ×_____ ▪ 근거(수주 계획·구역 확장·규제 일정 등): _____
Q36 면담	**상용 전환 후에도 GPU 수요가 지속됩니까?** (센터 운영 수익 계획에 사용) ▪ 상용 전환 시점: _____년 ▪ 예상 상시 추론 카드: ____장 ▪ 재학습 주기: _____개월마다 ▪ 상용 단계 GPU 조달: □ 센터 계속 이용 □ 자체 구매 □ 클라우드

VII 실증환경 및 기술지원 GPU 외에 무엇이 필요한가 · Q37~Q43

번호	문항 및 응답란
Q37 사전	**저장장치 요구사항은 무엇입니까?** ▪ 작업(핫) 스토리지: _____TB, 처리성능 _____GB/s (또는 _____K IOPS) ▪ 아카이브: _____TB, 보관 _____년 ▪ 백업 정책: _____ □ 불필요
Q38 사전	**네트워크·데이터 반입 요구사항은 무엇입니까?** ▪ 초기 반입 데이터량: _____TB ▪ 반입 방법: □ 온라인 전송(회선 _____Gbps) □ 물리 매체 반입 □ 현장 회선 직결 ▪ 원격 접속: □ VDI(격리 PC) □ VPN □ 불필요 ▪ 전용선·5G 특화망 요구: _____
Q39 면담	**소프트웨어 환경의 제약사항은 무엇입니까?** ▪ CUDA·드라이버 최소 버전: _____ ▪ 프레임워크·런타임: _____ ▪ 컨테이너 이미지(Dockerfile) 제공: □ 가능 □ 불가 ▪ 외부 모델(HuggingFace 등) 다운로드: □ 필요(사유: _____) □ 불필요 ▪ 상용 SW(MLOps 등) 라이선스의 하드웨어 종속 여부: _____
Q40 면담	**필요한 기술지원과 자체 운영 역량은 어느 정도입니까?** (복수 선택) □ 모델 배포·서빙 □ 실험 추적(MLflow/W&B) □ CI/CD □ 모니터링 □ 데이터 파이프라인 □ 대시보드 ▪ 자체 운영 수준: □ 자체 가능(지원 불요) □ 부분 지원 □ 완전 관리형 희망 ▪ 필요 교육 주제: _____ ▪ 이용 전 필수교육 요구: □ 예 □ 아니오
Q41 면담	**기업 시스템·외부 데이터와 연계가 필요합니까?** □ 항만공사 운영시스템 □ TOS/CTP □ PORT-MIS □ UNI-PASS □ VDR/ECDIS·항해장비 □ 국립해양조사원(수심·기상·조류) □ 자사 ERP/MES/WMS □ 불필요 ▪ 연계 방식: □ API □ DB 직접 □ 파일 □ 수동 ▪ 상대 기관 승인: □ 필요(기관: _____) □ 불필요
Q42 면담 ★ 핵심	**현장 실증 시 제약사항은 무엇입니까?** (실증 실험실·외부 연계 기획에 사용) ▪ 실증 장소: □ 안벽 □ 야적장 □ 터미널 내부 □ 선박 □ 관제센터 □ 기타 (_____) ▪ 출입 승인·안전교육: 기관 _____, 소요 _____일

번호	문항 및 응답란
	▪ 기간 제약(성수기·기상·크레인 가동 일정): _____ ▪ 통신 환경: □ 5G 특화망 필요 □ 유선 □ 현장 Wi-Fi 불충분 □ 자체 준비 ▪ 전원·설비 거치 요구: _____ ▪ 안전조치 필요사항: _____
Q43 면담	**외부 전문가 기술지원의 범위와 규모는 어느 정도입니까?** ▪ 지원 영역: □ 요구정의 □ 데이터 엔지니어링 □ 모델 개발 □ 성능검증 □ 현장 배포 □ 기타(____) ▪ 희망 규모: _____인월 × _____개월 ▪ 예산: 월 _____만원

VIII 실증성과 및 투자 타당성 비용과 지불 의사, 상용화 계획 · Q44~Q46

번호	문항 및 응답란
Q44 사전	**현재 GPU 관련 월 지출은 얼마입니까?** (항목별 기재) ▪ 클라우드 GPU: _____만원 (주 이용사: _____) ▪ 자사 장비 감가상각 환산: _____만원 (구매가 _____만원 / _____년 상각) ▪ 외주·라벨링·SaaS: _____만원 ▪ 기타: _____만원 ▪ 증빙(청구서·계약서) 제출: □ 가능 □ 불가
Q45 면담 ★ 핵심	**센터를 이용한다면 비용을 얼마까지 지불할 수 있습니까?** (지불의사, WTP) "센터가 Q22·Q29에서 답하신 사양과 동일한 구성을 제공한다면" ▪ 월 감내 가능 비용: _____만원 ▪ 예상 이용: 월 _____회 × 1회 _____시간 ▪ 자부담 가능액(공모 연계 시): _____만원 ▪ 무료 제공 시 추가로 필요한 서비스: _____
Q46 면담	**실증 완료 후 상용화·현장 확대 계획이 있습니까?** □ 있음 —시점 _____년, 대상 현장 _____, 예상 투자 _____만원 확대 방식: □ 자사 전 현장 □ 협력사 확산 □ SaaS화 □ 기타(_____) □ 없음(연구 목적) □ 검토 중

IX. 실증 참여의향 센터 개소 시 실제로 참여하는가 (신설) · Q47~Q50

번호	문항 및 응답란
Q47 면담 ★ 핵심	**센터 개소(2027~2028년 예정) 시 실증에 참여할 의향이 있습니까?** □ 확정 —희망 착수 _____년 _____월, 예상 사용기간 _____개월 □ 검토 —의사결정 시점 _____, 참여 조건 _____ □ 비참여 —사유: □ 입지 □ 보안 □ 타 기관 이용 중 □ 시기 불일치 □ 비용 □ 의무 없음
Q48 면담	**희망하는 이용 형태는 무엇입니까?** □ 시간당 종량제 □ 월정액 예약 슬롯 □ 프로젝트 패키지(일괄) □ 크레딧·바우처 □ 상관없음 ▪ 사유 또는 조건: _____
Q49 면담	**현재 다른 기관·서비스의 GPU를 이용하고 있습니까?** □ KISTI 등 공공 슈퍼컴퓨터 □ 지역 거점·테크노파크 □ 민간 클라우드 □ 자사 장비 □ 미사용

번호	문항 및 응답란
	▪ 미사용 시 이유: _____ ▪ 이용 중 불만 사항: □ 대기시간 □ 단가 □ 사양 □ 보안 □ 기술지원 □ 없음
Q50 면담	**GPU 외 센터 서비스 중 이용하고 싶은 것은 무엇입니까?** (상위 3개에 1~3 순위 기재) ( ) 데이터 라벨링·가공 ( ) 비식별 대행 ( ) MLOps 플랫폼 ( ) 현장 실증 연계(항만) ( ) 성능검증·공식 리포트 ( ) 전문인력 매칭 ( ) 교육·워크숍

응답 동의 면담 시 확인 · C01~C03

번호	문항 및 응답란
C01 면담	**응답 내용을 ISP·ISMP 수립(수요 집계·시설 계획)에만 사용하고, 보고서에는 기업명을 익명화·집계하여 반영하는 데 동의합니까?** □ 예 □ 아니오
C02 면담	**면담 중 노트 작성·녹음 및 사후 수치 확인 연락에 동의합니까?** □ 예 □ 아니오
C03 면담	**수치 근거 확인을 위한 자료(클라우드 청구서, 학습 로그 사본) 요청에 응할 수 있습니까?** □ 가능 □ 부분 가능 □ 어려움

부록 A. GPU 수요 산정식과 예시 응답이 GPU-h로 환산되는 방식

구분	산정식	관련 문항
학습 GPU-h/월	(1회 카드 수 × 1회 시간) × 월 실행 횟수 × 실험 배수 × (1 + 간접 비율)	Q22·Q23·Q24
추론 카드 수	⌈ 피크 부하 × 에이전트 계수 × (1 + 여유율) ÷ 카드 1장 실측 처리량 ⌉ × 모델당 병렬 장수	Q28·Q29(Q29-2)·Q30·Q26
추론 GPU-h/월	추론 카드 수 × 일 운영시간 × 주 운영일 × 4.345(주/월)	Q32
유효 수요	학습 GPU-h + 추론 GPU-h × (1 − 상용 API 처리 비중)	Q10
상시 환산 카드 수	유효 월 GPU-h ÷ (24 × 7 × 4.345 × 목표 가동률)	-

예시	학습	추론	합계
①영상감시·객체검출	H100 4장 × 6시간 = 24 GPU-h/회 × 월 3회 × 실험 3배 × 1.3(간접 30%) ≈ 281 GPU-h/월	피크 40fps × 1.2(여유) ÷ 실측 12fps/장 = 4장 24시간 × 7일 운영 4 × 24 × 7 × 4.345 ≈ 2,920 GPU-h/월	**≈ 3,201 GPU-h/월**
②LLM RAG 상담	H100 2장 × 8시간 = 16 GPU-h/회 × 월 1회 × 실험 2배 × 1.2(간접 20%) ≈ 38 GPU-h/월	동시 20세션 ÷ 실측 6세션/모델 = 4개(올림) 32B 모델은 2장 병렬 → 8장, 일 10시간 × 주 5일 8 × 10 × 5 × 4.345 ≈ 1,738 GPU-h/월	**≈ 1,776 GPU-h/월**
③상용 API 전용	Q10에서 'API 100%'인 경우 학습 수요만 집계	추론 수요는 0으로 처리	**학습분만**

부록 B. 원 질의서 대비 조정 내역 구 32문항 → 개정 문항

구분	내용
승계·보강	원 32문항의 질문 취지를 전량 승계하고 체크박스·단위 고정 등으로 보강 (아래 대응표 참조)
통합	구 Q04(목표 KPI) + 구 Q29(판정 지표) → Q04 (목표 + 기준선 + 측정 주체 + 판정 기간) 구 Q15(학습 횟수) + 구 Q16(병렬 실험) → Q23 (실험 배수·병렬 수 분리 기재)
분리	구 Q14(사양·시간) → Q22 (카드 수·시간·VRAM, GPU-h 산출) 구 Q23(분산학습) → Q26 (학습 분산과 추론 병렬 분리) 구 Q12(데이터 보안) → Q18(반출 제한) · Q20(보안 인증)
교체	구 Q31(비용절감 효과) → Q45 (조건부 지불의사, WTP) —서면으로는 답이 나오지 않는 문형 교정
신설	M01~M03(기본정보), Q05(편익), Q06(애로), Q10(자체/API), Q12(양자화), Q13(NPU), Q17(라벨링), Q19(반출 불가 대응), Q24(간접 비율), Q29·Q29-2(실측 처리량), Q30(요청당 부하), Q34(대기·선점), Q36(지속 수요), Q38(반입), Q39(SW 제약), Q42(현장 제약), Q47~Q50(참여의향), C01~C03(동의)
목적 대응	조사목적의 '실증 참여의향'은 원 질의서에 없던 항목 → IX장 신설

구 → 신 문항 대응표

구 문항	원 질문 요지	개정 문항	조정 내용
Q01	실증하려는 AI 서비스·기술	**Q01**	대상 업무·대체 방식 추가
Q02	기술개발 단계	**Q02**	체크박스화, 검증 장소·기간
Q03	해결하려는 현장 문제	**Q03**	빈도·손실 정량화
Q04	KPI·목표 수준	**Q04**	구 Q29와 통합, 기준선 필수화
Q05	AI 모델 유형	**Q07**	체크박스화
Q06	모델명·버전·파라미터·프레임워크	**Q08**	예시 제시
Q07	활용 방식(기존·미세조정·신규)	**Q09**	체크박스화
Q08	CPU·GPU 사양과 한계	**Q11**	한계 사례 기재
Q09	데이터 유형	**Q14**	유형별 물량 정량화
Q10	데이터 총량·건수·해상도	**Q15**	단위 고정
Q11	학습·추론 데이터 증가량	**Q16**	스트리밍/배치 분리
Q12	데이터 반입·전송·보안 제한	**Q18·Q20**	체크박스·승인 구조, 보안 인증
Q13	GPU 필요 작업	**Q21**	체크박스화
Q14	1회 학습 GPU·VRAM·시간	**Q22**	GPU-h 정의·근거 등급
Q15	월 학습 횟수	**Q23**	구 Q16과 통합
Q16	동시 실험 필요성	**Q23**	실험 배수·병렬 수 분리
Q17	추론 방식	**Q27**	체크박스화
Q18	요청량·동시 이용자·프레임	**Q28**	단위 택1 체계
Q19	허용 응답시간	**Q31**	모델 유형별 단위 고정

구 문항	원 질문 요지	개정 문항	조정 내용
Q20	추론 운영 시간	**Q32**	피크 배수·가용률 추가
Q21	전용/공유	**Q33**	공유 조건 구체화
Q22	GPU 필요 시점·기간	**Q25**	기한 고정 사유
Q23	분산학습 필요성	**Q26**	학습 분산/추론 병렬 분리
Q24	1~3년 증가 전망	**Q35**	배수로 기재
Q25	저장·네트워크·연계·도구	**Q37**	저장장치 단위 고정 (Q38·Q39 신설)
Q26	배포·MLOps 지원	**Q40**	자체 운영 역량 분리
Q27	현장·기업 시스템 연결	**Q41**	시스템 목록화 (Q42 신설)
Q28	외부 전문가 지원 범위	**Q43**	규모·예산 추가
Q29	PoC 성공 판정 지표	**Q04**	구 Q04와 통합
Q30	현재 GPU 사용 비용	**Q44**	항목 분해·증빙
Q31	사용빈도·비용절감 효과	**Q45**	WTP 문형으로 교체
Q32	상용화·확대 계획	**Q46**	확대 방식 추가

부록 C. 제출·회수 안내

① 사전서베이(XLSX '2_기업입력' 시트)를 면담 7일 전까지 이메일로 회송해 주십시오. 미회수 시 면담 초반 20분이 서면 작성에 쓰입니다.

② 면담(약 90분)은 회수된 정량값의 근거(실측 로그·청구서)를 확인하고, '미확인' 항목의 대체값을 도출하는 데 시간을 배분합니다.

③ 문의: 수행기관 담당자 _____ ☎ _____ e-mail _____

- 감사합니다 -